

Résumé du Projet d'Analyse de Données

Ce projet a été créé dans le cadre d'un cours en L3 Double Licence Economie et Gestion (parcours Diplôme Universitaire : Classe universitaire Préparatoire aux Grandes Ecoles) à l'[université du Mans](#). L'objectif principal était d'identifier les tendances du marché locatif à New Delhi et d'évaluer les facteurs influençant le prix des loyers. Ce projet a permis de mettre en pratique une grande partie des concepts et méthodes enseignés tout au long de la licence, notamment en économétrie, en inférence statistique et en analyse de données. Le projet a entièrement été réalisé en Python, à l'exception d'une partie traitée en Excel.

Le projet a débuté par la récupération des données via le web scraping. Les données brutes, initialement désorganisées, ont été nettoyées et structurées à l'aide d'outils comme Excel et Python, en utilisant des bibliothèques comme Pandas. Cette étape a permis de supprimer les colonnes inutiles, de convertir les unités de mesure et de gérer les valeurs manquantes et aberrantes. Ce travail de prétraitement a été essentiel pour garantir la qualité des analyses ultérieures.

L'analyse univariée a ensuite permis de décrire chaque variable individuellement, en utilisant des indicateurs de tendance centrale (moyenne, médiane) et de dispersion (variance, écart-type). Par exemple, le prix moyen des loyers est de 64 347 roupies, mais la médiane est de 38 000 roupies, révélant une distribution asymétrique avec des valeurs extrêmes.

L'analyse bivariée a exploré les relations entre les variables. Par exemple, la corrélation linéaire entre le prix et la superficie est de 0.86, indiquant une relation linéaire forte. Nous avons également utilisé des diagrammes de dispersion et des boxplots pour visualiser ces relations. Des tests, comme le test de Kruskal-Wallis, ont été utilisés pour comparer les prix entre les annonces postées par les agences immobilières et les propriétaires, révélant une différence significative entre ces deux groupes. Nous avons également utilisé des méthodes comme le rapport de corrélation, les tableaux de contingence ou encore la mesure du Khi-2 pour compléter cette analyse bivariée.

Par ailleurs, nous avons pu réaliser l'analyse de plusieurs variables à l'aide de l'Analyse en Composantes Principales (ACP), une méthode enseignée en L3 dans le cours d'analyse de données. L'ACP a permis de réduire la dimension des données en transformant les variables corrélées en composantes principales non corrélées. Par exemple, les deux premières composantes expliquent 69% de la variance totale, ce qui est suffisant pour une bonne représentation des données. Des cercles de

corrélations ont été utilisés pour visualiser les relations entre les variables et les axes principaux.

Par la suite, l'inférence statistique a permis de tirer des conclusions sur la population à partir de l'échantillon. Nous avons utilisé des tests de normalité, comme le test de Lilliefors et le test de Jarque-Bera, pour vérifier si les données suivent une distribution normale. Ces tests, enseignés en L2 et L3, ont montré que les données ne suivent pas une distribution normale, ce qui a influencé le choix des méthodes d'analyse. Par exemple, le test de Kruskal-Wallis, une alternative non paramétrique à l'ANOVA, a été utilisé pour comparer les moyennes de deux groupes.

Enfin, le modèle de régression linéaire multiple, un concept central du cours d'économétrie de L2 et L3, a été utilisé pour prédire le prix des loyers en fonction de plusieurs variables explicatives. Le modèle a montré que les variables *area*, *bathroom* et *bedroom* ont un impact significatif sur le prix. Par exemple, une augmentation de 1 square foot entraîne une augmentation moyenne du prix de 42.79 roupies, toutes choses égales par ailleurs. Le meilleur coefficient de détermination R^2 que nous avons pu avoir était de 0.625, signifiant que 62.5% de la variance du prix est expliquée par les variables indépendantes. Nous avons également pu traiter des problèmes de multi colinéarité entre les variables.

Ce projet a permis de mettre en pratique une grande partie des concepts et méthodes enseignés tout au long de la licence. Les cours d'économétrie de L2 et L3 ont fourni les bases pour la construction et l'interprétation des modèles de régression. Les cours d'inférence statistique et théorie des tests ont permis de valider les hypothèses et de tirer des conclusions sur la population. Enfin, le cours d'analyse de données a fourni les outils nécessaires pour explorer et visualiser les données, notamment à travers l'ACP et les tableaux de contingence. Ce projet a non seulement renforcé mes compétences en analyse de données, mais il a également montré l'importance de la rigueur méthodologique et de la compréhension approfondie des concepts statistiques. Il a également souligné l'importance de la gestion des données brutes et de la préparation des données avant toute analyse, une étape cruciale souvent sous-estimée.

En conclusion, ce projet a été une excellente opportunité pour appliquer les connaissances acquises au cours de la licence à un problème concret, tout en développant des compétences pratiques en programmation et en analyse de données.

Gwezheneg ORY